

PointProgrammerNet: 面向流式点云理解的固定状态可加程序

Dian Yu

University of New South Wales, Sydney, NSW 2052, Australia

dian.yu2@student.unsw.edu.au

ORCID: <https://orcid.org/0009-0002-0107-1014>

摘要

多数点云网络通过重新访问已保存的点、重建邻域或执行全局最大池化来获得上下文。这些操作适合离线处理，却使持续增长的点流依赖完整历史。PointProgrammerNet 用三个固定的 128×170 矩阵取代点历史。每个观测点产生一个表示“写到哪里”的归一化空间地址，以及一个表示“写入什么”的值向量；二者的外积直接加到矩阵中。因此，不同时间或不同设备编码的点云分块可以通过矩阵加法精确合并，状态也支持相减和指数衰减。分割任务在指定坐标读取矩阵，分类任务则在删除全部输入点后仅使用矩阵。本文证明输入顺序不变性、分块与分布式编码等价性、固定保留内存，以及输出对新增证据的连续依赖。使用 XYZ 输入时，模型在 ShapeNetPart 上取得 92.95% 点准确率、82.58% 实例 mIoU 和 79.10% 类别 mIoU，在 ModelNet40 上取得 86.59% 分类准确率。三个 float32 状态始终占用 255 KiB，与点流长度无关。当累计点数达到 8,192 时，只更新新分块比重建完整状态快 $6.06\times$ ，相对状态误差仍低于 10^{-6} 。这些结果展示了用有界、可直接更新和合并的状态取代不断增长的点历史时，其精度代价和实际收益。

关键词：点云；流式学习；可加状态；快速权重程序器；分割；分类

1 引言

点云在数学上是无序集合，但传感器通常按时间持续获得点。同一帧内的处理应与点的排列顺序无关，跨帧处理也不应要求重放全部历史。PointNet [4] 通过对逐点特征进行对称最大池化获得全局描述，PointNet++ [5]

则建立多尺度度量邻域。二者在离线任务中都很有效，但最大值不是可加状态：固定摘要通常无法仅凭简单加法同时支持删除、独立分块合并和连续加权证据。

本文研究一个更严格的设定：一个点写入状态后即可被删除。之后的计算只能访问固定矩阵；分割任务额外允许访问查询坐标。学习得到的键把每个点分配到状态的多个行，二阶值则记录质量、位置、学习内容和交叉矩。所有逐点写入相加后形成固定尺寸状态。

因此，独立点云分块可以直接合并，已保存的子集状态可以相减，旧证据可以衰减，新增点也不需要触碰历史观测。相同代数还可用于分布式感知：边缘设备分别编码不同空间区域或时间片，只传输固定矩阵，中心节点相加后再执行分类或分割。分割头读取一个由坐标查询的连续场，不保存历史点特征；分类头只读取状态行，完整点列表可被删除。

本文的主要贡献如下：

- 提出三尺度二阶快速权重程序器（FWP）状态，其存储量不随已观测点数增长；
- 采用可加逐点写入，在不重放分块内容的情况下支持精确流式更新、分层合并和分布式聚合；
- 设计坐标条件分割头和纯状态分类头，两者都不对解码后的点执行池化；
- 从理论和实验两方面验证可加性、状态操作、识别精度和更新开销。

本文使用的紧凑 PointNet++ 实现是受控基线，用来衡量固定状态约束的精度代价，不声称是标准实现的完整复现。

2 相关工作

PointNet 对逐点变换后的特征执行最大池化 [4]，PointNet++ 进一步引入分层度量邻域 [5]。Deep Sets 研究基于求和的置换不变函数 [9]，Set Transformer 使用注意力和诱导点 [3]。核化注意力可以递归计算 [2]，快速权重程序器则用可加外积或 delta 修正规则更新记忆 [6]。PointProgrammerNet 将这一思想用于几何数据：固定状态保存空间统计量、学习特征及其二阶关系，并且在释放输入点后仍可使用。本文在 ModelNet40 [7] 上测试分类，在由 ShapeNet [1] 派生的 ShapeNetPart [8] 上测试部件分割。

3 方法

令点云为 $X = \{\mathbf{x}_i\}_{i=1}^N$ ，归一化坐标 $\mathbf{x}_i \in \mathbb{R}^3$ 。论文主实验只使用 XYZ。若以后加入法线、颜色或强度，可将它们扩展到写入值中，而不改变状态更新规则。

核心思路是把每个点变成两个向量：空间地址 $\mathbf{k}_s(\mathbf{x}_i)$ 决定该点分别写入矩阵的哪些行以及写入多少，值 $\mathbf{v}_s(\mathbf{x}_i)$ 表示需要保存的信息。两个向量的外积是一个矩阵，所有点的外积矩阵相加就是最终状态。因此，对任意两个点多重集合 A 和 B ，

$$\mathbf{S}(A \uplus B) = \mathbf{S}(A) + \mathbf{S}(B). \quad (1)$$

其中， $\uplus$ 表示保留重复点的集合并， $\mathbf{S}(\cdot)$ 表示三个状态矩阵组成的整体。式 (1) 表明， A 和 B 可以在不同时间甚至不同设备上独立编码，合并时只需矩阵相加，不必再次访问原始点。

模型包含细、中、粗三个分支，记为 $s \in \{f, m, b\}$ 。三个分支具有完全相同的容量和计算结构：每个状态都是 $R = 128$ 行、 $D = 170$ 列，分割读出网络的尺寸也相同；但三个分支的参数彼此独立。它们的半径初始值分别为 0.08, 0.20, 0.60，随后均可学习。“细、中、粗”只描述初始空间范围，并不人为规定每个分支必须学习某种语义功能。沿用快速权重研究中的名称，本文把每个累计矩阵称为 FWP 状态。就具体计算而言，它只是一个保存加权累计和的固定矩阵，并不逐个保存输入点。

状态在推理时由当前输入生成，与模型参数不同。训练真正学习的是逐点网络、空间中心、半径和输出网络。处理一个新物体或一条新点流时，三个矩阵从零开始；每个点只增加一次矩阵更新，随后即可释放该点。以后必须保留的点派生信息只有这三个累计矩阵。本文关于可加性的结论针对训练完成后的推理模式，此时 BatchNorm 使用固定的运行统计量。

3.1 将一个点写入状态

每个分支的写入过程分别回答两个问题：当前点包含什么信息，以及这些信息应当写到矩阵的哪些行。

第一步，两层逐点网络把坐标变成 32 维特征：

$$\mathbf{g}_s(\mathbf{x}) = \text{ReLU}(\text{BN}(W_{s2} \text{ReLU}(\text{BN}(W_{s1}\mathbf{x} + \mathbf{b}_{s1})) + \mathbf{b}_{s2})) \in \mathbb{R}^{32}. \quad (2)$$

其中， s 是分支编号， $\mathbf{x} \in \mathbb{R}^3$ 是一个坐标， W_{s1}, W_{s2} 和 $\mathbf{b}_{s1}, \mathbf{b}_{s2}$ 是可学习仿射参数，BN 表示 BatchNorm， $\mathbf{g}_s(\mathbf{x})$ 是网络从该点提取的内容。两个隐藏

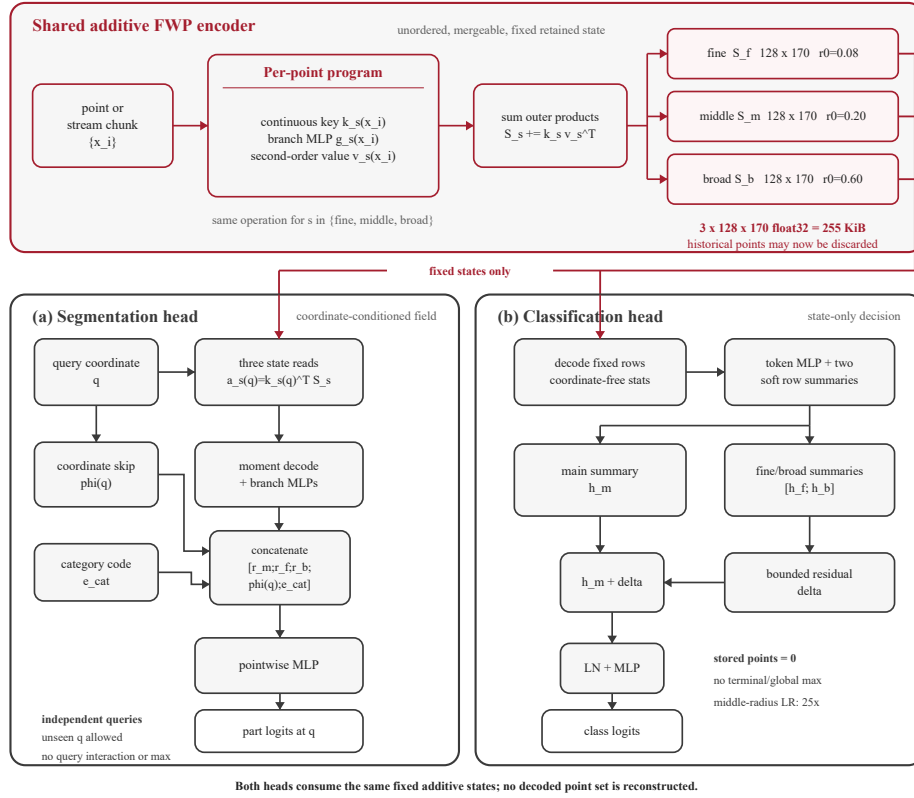


图 1: PointProgrammerNet 架构。历史点被删除后, 红色路径传递三个等尺寸可加 FWP 状态。分割头在查询坐标 q 处读取每个状态, 再拼接解码上下文、坐标跳连和类别编码。分类头解码固定状态行, 并将有界的细尺度和粗尺度残差加到中尺度状态摘要上。两个任务头都不重建解码点集, 也不对其执行池化。

仿射层宽度均为 32。三个分支使用各自独立的参数，因此状态尺寸相等并不会迫使它们学习相同特征。

第二步，坐标产生 128 维空间地址。分支 s 的每一行 j 对应一个可学习中心 $\mathbf{c}_{sj} \in \mathbb{R}^3$ 。中心初始位置取未加扰 Sobol 序列的前 128 个点，并映射到 $[-0.9, 0.9]^3$ 。中心写成 $\mathbf{c}_{sj} = 0.95 \tanh(\boldsymbol{\theta}_{sj})$ ，所以训练过程中始终位于归一化坐标立方体内。对正半径 $r_s = \exp(-\lambda_s)$ ，

$$\ell_{sj}(\mathbf{x}) = -\frac{\|\mathbf{x} - \mathbf{c}_{sj}\|_2^2}{2r_s^2}, \quad (3)$$

$$k_{sj}(\mathbf{x}) = \frac{\exp \ell_{sj}(\mathbf{x})}{\sum_{u=1}^R \exp \ell_{su}(\mathbf{x})}. \quad (4)$$

其中， $\boldsymbol{\theta}_{sj}$ 是用来得到中心 $\mathbf{c}_{sj}$ 的无约束参数， λ_s 是可学习的逆半径对数， ℓ_{sj} 是坐标到第 j 个中心的距离分数， k_{sj} 是写入第 j 行的比例。分母中的 $u = 1, \dots, R$ 遍历全部行，因此地址向量 $\mathbf{k}_s(\mathbf{x}) = [k_{s1}, \dots, k_{sR}]^\top$ 的元素和为 1。每个点以连续权重写入所有行，距离较近的中心获得更大权重；整个过程没有最近中心硬选择，也不需要把当前点与其他输入点比较。较小的半径使写入集中在较少的行，较大的半径使写入分布更宽。

第三步，模型构造 170 维值向量：

$$\mathbf{v}_s(\mathbf{x}) = [1, \mathbf{x}, \mathbf{g}_s, \text{vec}(\mathbf{x}\mathbf{g}_s^\top), x^2, y^2, z^2, xy, xz, yz, \mathbf{g}_s \odot \mathbf{g}_s]. \quad (5)$$

其中， vec 表示矩阵展平， $\odot$ 表示逐元素乘法， x, y, z 是 $\mathbf{x}$ 的三个分量。各部分依次为：1 个单位质量、3 个坐标、32 个学习特征、96 个坐标与特征乘积、6 个 $\mathbf{x}\mathbf{x}^\top$ 的互异元素，以及 32 个特征平方项，总维度为 $1+3+32+96+6+32=170$ 。开头的 1 记录每一行接收到的证据总量，读取时可作为加权平均的分母。平方项和交叉乘积保存均值无法表达的离散程度与相关关系。

一个点增加如下外积矩阵：

$$\Delta \mathbf{S}_s(\mathbf{x}) = \mathbf{k}_s(\mathbf{x})\mathbf{v}_s(\mathbf{x})^\top, \quad [\Delta \mathbf{S}_s(\mathbf{x})]_{j,:} = k_{sj}(\mathbf{x})\mathbf{v}_s(\mathbf{x})^\top. \quad (6)$$

其中， $\Delta \mathbf{S}_s(\mathbf{x}) \in \mathbb{R}^{128 \times 170}$ 是该点对分支 s 的更新，上标 $\top$ 表示转置， $[\cdot]_{j,:}$ 表示第 j 行。因此，矩阵的一行保存的是加权累计和，并不是某个被选中的点。对 N 个点，令 $\mathbf{K}_s \in \mathbb{R}^{N \times 128}$ 的第 i 行保存第 i 个点的地址， $\mathbf{V}_s \in \mathbb{R}^{N \times 170}$ 的第 i 行保存第 i 个点的值，则

$$\mathbf{S}_s(X) = \sum_{i=1}^N \mathbf{k}_s(\mathbf{x}_i)\mathbf{v}_s(\mathbf{x}_i)^\top = \mathbf{K}_s^\top \mathbf{V}_s \in \mathbb{R}^{128 \times 170}. \quad (7)$$

其中, i 是输入点编号, j 是固定状态行编号。在流式处理中, 模型只为新到达的分块计算 $\mathbf{K}_s^\top \mathbf{V}_s$, 将结果加到持久状态后即可释放该分块。除浮点累加顺序造成的微小误差外, 如何划分分块不会改变最终状态。

3.2 分割读出

分割任务需要预测坐标 $\mathbf{q} \in \mathbb{R}^3$ 处的部件类别。模型用写入时相同的心和半径计算查询地址 $\mathbf{k}_s(\mathbf{q})$, 再从状态行中读取加权组合:

$$\mathbf{a}_s(\mathbf{q}) = \mathbf{k}_s(\mathbf{q})^\top \mathbf{S}_s = \sum_i w_{si}(\mathbf{q}) \mathbf{v}_s(\mathbf{x}_i)^\top, \quad w_{si}(\mathbf{q}) = \mathbf{k}_s(\mathbf{q})^\top \mathbf{k}_s(\mathbf{x}_i). \quad (8)$$

其中, $\mathbf{a}_s(\mathbf{q}) \in \mathbb{R}^{170}$ 是原始读取结果, $w_{si}(\mathbf{q})$ 是观测点 i 对查询坐标 $\mathbf{q}$ 的有效贡献; 两个空间地址越重合, 该值通常越大。读取所需的加权和已经保存在 $\mathbf{S}_s$ 中, 因此无需还原或重新访问原始点。

令 $\mu_s(\mathbf{q}) = \sum_i w_{si}(\mathbf{q})$ 表示读取质量。为防止分母接近零, 实现中使用

$$\epsilon_s = 10^{-3} \text{mean}_{\mathbf{q}'} \mu_s(\mathbf{q}') + 10^{-20}, \quad \tilde{\mu}_s(\mathbf{q}) = \max(\mu_s(\mathbf{q}), \epsilon_s), \quad (9)$$

其中, $\mathbf{q}'$ 遍历同一样本的查询坐标。这个停止梯度的数值下限只使用查询质量, 不汇集点特征, 也不会查询之间传播梯度; 单个坐标仍可独立计算。为简化记号, 令 $w_i = w_{si}(\mathbf{q})$, 则状态中保存的各类和可以还原为

$$\begin{aligned} \bar{\mathbf{x}}_s &= \tilde{\mu}_s^{-1} \sum_i w_i \mathbf{x}_i, & \bar{\mathbf{g}}_s &= \tilde{\mu}_s^{-1} \sum_i w_i \mathbf{g}_s(\mathbf{x}_i), \\ E_{xg,s} &= \tilde{\mu}_s^{-1} \sum_i w_i \mathbf{x}_i \mathbf{g}_s(\mathbf{x}_i)^\top, & E_{xx,s} &= \tilde{\mu}_s^{-1} \sum_i w_i \mathbf{x}_i \mathbf{x}_i^\top, \\ E_{gg,s} &= \tilde{\mu}_s^{-1} \sum_i w_i \mathbf{g}_s(\mathbf{x}_i) \odot \mathbf{g}_s(\mathbf{x}_i). \end{aligned} \quad (10)$$

其中, $\bar{\mathbf{x}}_s$ 和 $\bar{\mathbf{g}}_s$ 是局部坐标均值与特征均值; $E_{xg,s}$ 描述位置和学习内容如何共同变化; $E_{xx,s}$ 描述几何分布; $E_{gg,s}$ 描述特征能量。这些量都来自一次矩阵读取。

模型把上述量整理成

$$\begin{aligned} \mathbf{d}_s(\mathbf{q}) &= [\bar{\mathbf{g}}_s, \bar{\mathbf{x}}_s - \mathbf{q}, \log \tilde{\mu}_s, \text{vec}(E_{xg,s} - \mathbf{q} \bar{\mathbf{g}}_s^\top), \\ &\quad \text{vech}(E_{xx,s} - \bar{\mathbf{x}}_s \bar{\mathbf{x}}_s^\top), \sqrt{[E_{gg,s} - \bar{\mathbf{g}}_s \odot \bar{\mathbf{g}}_s]_+ + 10^{-8}}]. \end{aligned} \quad (11)$$

其中, vech 保留对称 3×3 矩阵的 6 个互异元素, $[\cdot]_+$ 将浮点误差造成的微小负方差截断为零。六个部分的维度分别为 32, 3, 1, 96, 6, 32, 依次表达局部

内容、局部中心相对查询的位移、可用证据量、位置与内容的关系、几何协方差和特征标准差。

三个分支都独立使用完全相同的 $170 \rightarrow 160 \rightarrow 160$ 网络，并在每层后使用 BatchNorm 和 ReLU，最终得到 $\mathbf{r}_s(\mathbf{q}) \in \mathbb{R}^{160}$ 。任何分支都没有更宽或更深的解码器。三个结果直接拼接，使最终网络可以分别利用不同初始空间范围的信息：

$$\mathbf{z}_{\text{seg}}(\mathbf{q}) = h_{\text{seg}}([\mathbf{r}_f; \mathbf{r}_m; \mathbf{r}_b; \phi(\mathbf{q}); \mathbf{e}_{\text{cat}}]). \quad (12)$$

其中，分号表示拼接； $\phi(\mathbf{q}) \in \mathbb{R}^{32}$ 是式 (2) 中尺度分支对查询坐标产生的特征； $\mathbf{e}_{\text{cat}} \in \mathbb{R}^{16}$ 是 ShapeNetPart 物体类别的独热编码； $\mathbf{z}_{\text{seg}} \in \mathbb{R}^{50}$ 是 50 个部件类别分数。 h_{seg} 的尺寸为 $528 \rightarrow 256 \rightarrow 128 \rightarrow 50$ ，前两个仿射层后使用 BatchNorm、ReLU 和 0.3 dropout。坐标路径 $\phi(\mathbf{q})$ 的作用类似 U-Net 跳连：精确查询位置绕过压缩状态，历史上下文则只能来自三个固定矩阵。分割头不对查询点执行最大池化，也不在查询点之间交换学习特征。编码完成后可以删除历史点特征，只需保留将来需要标注的坐标。相同公式还能查询原始点集中不存在的坐标，但本文尚未测量这种插值能力。

3.3 分类读出

分类任务没有查询坐标，也不保留输入点。模型先把固定状态的每一行还原为归一化统计量。把 $\mathbf{S}_s$ 的第 j 行写成

$$[\mu_{sj}, \mathbf{p}_{sj}, \mathbf{f}_{sj}, \text{vec}(\mathbf{C}_{sj}), \text{vech}(\mathbf{Q}_{sj}), \mathbf{u}_{sj}], \quad (13)$$

其中， $\mu_{sj} \in \mathbb{R}$ 是累计质量， $\mathbf{p}_{sj} \in \mathbb{R}^3$ 是坐标和， $\mathbf{f}_{sj} \in \mathbb{R}^{32}$ 是特征和， $\mathbf{C}_{sj} \in \mathbb{R}^{3 \times 32}$ 是坐标与特征乘积的和， $\mathbf{Q}_{sj} \in \mathbb{R}^{3 \times 3}$ 是对称的坐标二阶矩之和， $\mathbf{u}_{sj} \in \mathbb{R}^{32}$ 是特征平方和。 $\mathbf{Q}_{sj}$ 只需保存六个互异元素。为防止分母接近零，定义

$$\tilde{\mu}_{sj} = \max\left(\mu_{sj}, 10^{-4} R^{-1} \sum_{u=1}^R |\mu_{su}| + 10^{-20}\right). \quad (14)$$

这里的 u 只是对 $R = 128$ 行求和时使用的编号；反向传播时，数值下限项被视为常数。再令 $\bar{\mu}_s = R^{-1} \sum_u \tilde{\mu}_{su}$ 、 $\bar{\mathbf{x}}_{sj} = \mathbf{p}_{sj} / \tilde{\mu}_{sj}$ 、 $\bar{\mathbf{g}}_{sj} = \mathbf{f}_{sj} / \tilde{\mu}_{sj}$ 、 $E_{xg,sj} = \mathbf{C}_{sj} / \tilde{\mu}_{sj}$ 、 $E_{xx,sj} = \mathbf{Q}_{sj} / \tilde{\mu}_{sj}$ 、 $E_{gg,sj} = \mathbf{u}_{sj} / \tilde{\mu}_{sj}$ 。送入行网络的向量为

$$\mathbf{d}_{sj}^{\text{row}} = [\bar{\mathbf{g}}_{sj}, \bar{\mathbf{x}}_{sj}, \log(\tilde{\mu}_{sj} / \bar{\mu}_s), \text{vech}(E_{xx,sj} - \bar{\mathbf{x}}_{sj} \bar{\mathbf{x}}_{sj}^\top), \sqrt{[E_{gg,sj} - \bar{\mathbf{g}}_{sj} \odot \bar{\mathbf{g}}_{sj}]_+ + 10^{-8}}, \text{vec}(E_{xg,sj} - \bar{\mathbf{x}}_{sj} \bar{\mathbf{g}}_{sj}^\top)]. \quad (15)$$

六个部分的维度依次为 32, 3, 1, 6, 32, 96, 合计 170。它们分别表示特征均值、质心、相对行质量、坐标协方差、特征标准差以及坐标与特征的协方差。这与分割读出的统计量相对应；除以 $\tilde{\mu}_{sj}$ 后，累计和变成均值，使不同输入点数得到的量处于可比较的尺度。

每个分支使用独立的 $170 \rightarrow 128 \rightarrow 128$ 行编码网络，并使用 LayerNorm 和 GELU。令 $\mathbf{T}_s \in \mathbb{R}^{R \times 128}$ 表示编码后的 128 行。随后，两组可学习评分分别对这 128 行做加权求和：

$$\begin{aligned} \mathbf{U}_s &= \text{softmax}_{\text{rows}}(\text{score}_s(\mathbf{T}_s)) \in \mathbb{R}^{R \times 2}, \\ \mathbf{h}_s &= H_s(\text{vec}(\mathbf{U}_s^\top \mathbf{T}_s)) \in \mathbb{R}^{256}. \end{aligned} \quad (16)$$

其中， $\text{score}_s : \mathbb{R}^{128} \rightarrow \mathbb{R}^2$ 为每一行产生两个分数；softmax 分别在两列分数的 128 行上归一化； $\mathbf{U}_s$ 保存两组行权重； $H_s : \mathbb{R}^{256} \rightarrow \mathbb{R}^{256}$ 由仿射层、LayerNorm 和 GELU 组成； $\mathbf{h}_s$ 是分支摘要。这里汇总的是固定 128 行矩阵，而不是长度随输入变化的点列表，因此存储量和读出开销不随历史点数增长。

中尺度摘要作为参考，细尺度和粗尺度摘要提供有界修正：

$$\boldsymbol{\delta} = \sigma(a) \tanh(W[\mathbf{h}_f; \mathbf{h}_b] + \mathbf{b}), \quad (17)$$

$$\mathbf{z}_{\text{cls}} = h_{\text{cls}}(\text{LN}(\mathbf{h}_m + \boldsymbol{\delta})). \quad (18)$$

其中， $\mathbf{h}_f, \mathbf{h}_m, \mathbf{h}_b \in \mathbb{R}^{256}$ 是三个分支摘要； $W \in \mathbb{R}^{256 \times 512}$ 和 $\mathbf{b} \in \mathbb{R}^{256}$ 将细、粗摘要的拼接投影到 256 维； $\sigma(a)$ 是取值在 0 到 1 之间的可学习标量；逐元素 tanh 限制修正量 $\boldsymbol{\delta}$ 的幅度；LN 表示 LayerNorm。分类器 h_{cls} 为 $256 \rightarrow 256 \rightarrow 40$ ，使用 GELU 和 0.3 dropout， $\mathbf{z}_{\text{cls}}$ 是 40 个 ModelNet 类别分数。 W 和 $\mathbf{b}$ 初始化为零， $\sigma(a)$ 初始为 0.1，因此训练从中尺度摘要开始，再逐渐接纳有用的细、粗尺度证据。三个半径均可学习；中尺度半径使用 $25\times$ 学习率且不使用权重衰减，其余参数使用基础优化器设置。

3.4 形式性质

命题 1 (置换不变性与可加性). 对每个分支，式 (7) 与点的输入顺序无关，并且 $\mathbf{S}_s(\biguplus_t X_t) = \sum_t \mathbf{S}_s(X_t)$ 。

其中， t 是任意点分块的编号， X_t 是第 t 个分块。

证明. 每个点只贡献一个矩阵。有限和在实数运算中与加法顺序和分组无关；实际计算中的微小差异仅来自浮点累加顺序。 $\square$

推论 1. 分块可直接相加。若已保存子集状态 $\mathbf{S}_s(Y)$, 则 $\mathbf{S}_s(X \setminus Y) = \mathbf{S}_s(X) - \mathbf{S}_s(Y)$ 。指数遗忘为 $\mathbf{S}_{s,t} = \rho \mathbf{S}_{s,t-1} + \mathbf{S}_s(X_t)$, 其中 $0 \leq \rho \leq 1$ 。

其中, Y 是需要删除的点子集, t 是帧编号, X_t 是新到达的帧, ρ 是上一时刻状态的保留比例。

推论 2 (分布式等价性). 设设备 d 在共享坐标系中观察到多重集合 $X^{(d)}$, 并使用相同编码器。中心节点可以构造

$$\mathbf{S}_s^{\text{global}} = \sum_{d=1}^D \mathbf{S}_s(X^{(d)}) = \mathbf{S}_s \left(\biguplus_{d=1}^D X^{(d)} \right). \quad (19)$$

因此, 无论使用哪一种任务头, 其输入状态都与集中式编码相同, 差别只能来自浮点累加顺序。

其中, D 是设备数量, d 是设备编号, $X^{(d)}$ 是设备 d 的本地点多重集合, $\mathbf{S}_s^{\text{global}}$ 是中心节点得到的分支状态。

式 (19) 将感知与推理解耦。设备可在编码后删除本地点, 只发送三个固定矩阵; 中间节点也可按任意树结构或到达顺序继续求和。服务器执行分类只需合并状态; 执行分割还需要待查询坐标及类别编码。严格等价要求所有设备共享模型权重、坐标归一化方式和参考坐标系。

命题 2 (固定存储和增量更新). 保留内存为 $O(\sum_s R_s D_s)$, 与历史点数无关。编码 M 个新点的外积开销为 $O(M \sum_s R_s D_s)$, 也与历史长度无关。

其中, R_s 和 D_s 分别是分支 s 的行数和列数, M 是新到达的点数。

证明. 系统只保留固定矩阵; 无论先前包含多少分块, 新分块都产生同样规模的矩阵乘法。□

命题 3 (证据和查询的连续性). 对证据强度 $t \in [0, 1]$, 令

$$\mathbf{S}_s(t) = \mathbf{S}_s^{\text{old}} + t \mathbf{k}_s(\mathbf{x}) \mathbf{v}_s(\mathbf{x})^\top. \quad (20)$$

分类 *logits* 和固定查询坐标下的分割 *logits* 对 t 连续且分段光滑; 固定状态下的分割 *logits* 对 $\mathbf{q}$ 连续且分段光滑。

其中, $\mathbf{S}_s^{\text{old}}$ 是写入新观测前的状态, $\mathbf{x}$ 是该观测, t 将其证据强度从未写入 ($t = 0$) 调节到完整写入 ($t = 1$)。

证明. 状态是 t 的仿射函数。式 (4) 中的高斯距离权重、softmax、线性层、使用正数下限的除法、ReLU/GELU 和加入稳定常数的平方根都是连续函数；它们的复合也是连续且分段可微的。□

状态随证据强度线性变化。Logits 和概率通常以非线性但连续的方式变化；离散的 $\arg\max$ 标签则可在决策边界处跳变。该连续性来自模型方程；校准和时间稳定性仍需通过实验回答。

3.5 未来的帧级 delta 规则

令 $\mathbf{K}_{s,t}, \mathbf{V}_{s,t}$ 打包第 t 帧的全部点，未来可研究以下自适应状态转移：

$$\mathbf{S}_{s,t} = \rho \mathbf{S}_{s,t-1} + \eta_t \mathbf{K}_{s,t}^\top (\mathbf{V}_{s,t} - \mathbf{K}_{s,t} \mathbf{S}_{s,t-1}). \quad (21)$$

其中， $\mathbf{K}_{s,t}$ 和 $\mathbf{V}_{s,t}$ 分别包含第 t 帧在分支 s 上的全部键和值， ρ 是旧状态保留比例， η_t 是 delta 更新步长。该形式来自快速权重 delta 规则 [6]。若帧内点顺序由置换矩阵 P 改变，则 $\mathbf{K}' = P\mathbf{K}$ 、 $\mathbf{V}' = P\mathbf{V}$ ；由于 $P^\top P = I$ ，修正项保持不变。因此帧内点仍是无序的，而帧顺序进入递归状态。该扩展会主动放弃跨帧的严格可加性，本文实验未使用它。

4 实验

4.1 实验协议

每个物体先中心化，再用 XYZ 最大绝对坐标归一化；每个样本使用 1,024 个点。ShapeNetPart 包含 13,972 个训练形状和 2,874 个测试形状；ModelNet40 包含 9,840 个训练形状和 2,468 个测试形状。模型训练 20 个 epoch，使用 AdamW、基础学习率 3×10^{-3} 、权重衰减 10^{-4} 和余弦衰减；分割和分类批大小分别为 16 和 32。分类使用 0.1 标签平滑。所有结果报告种子 0、1、2 的均值和总体标准差。密度偏移测试按 $\exp(2.5\mathbf{x}^\top \mathbf{d})$ 给点分配无放回采样概率，其中 $\mathbf{d}$ 是由固定随机种子生成的单位方向。紧凑 PointNet++ 是本地受控基线。分类实验中的较宽 PointNet 有 442,838 个参数，与 529,426 参数的纯状态分类模型并非严格配平。

4.2 准确率

PointProgrammerNet 的点准确率、实例 mIoU 和类别 mIoU 分别比轻量 PointNet++ 低 0.46、1.30 和 0.41 个百分点，但参数量少 40.3%，并且

表 1: ShapeNetPart 部件分割结果。输入为 XYZ，每个样本 1,024 个点，结果为三个随机种子的均值 $\pm$ 总体标准差。

模型	点准确率	实例 mIoU	类别 mIoU	参数量
轻量 PointNet++	93.41 ± 0.05	83.88 ± 0.11	79.51 ± 0.24	573,106
PointProgrammerNet	92.95 ± 0.02	82.58 ± 0.15	79.10 ± 0.25	341,909

不对历史点或解码后的查询点执行最大池化。

表 2: ModelNet40 分类结果。结果为三个随机种子的均值 $\pm$ 总体标准差。

模型	干净准确率	密度偏移准确率	下降	参数量
轻量 PointNet++	89.84 ± 0.43	85.47 ± 0.88	4.38 ± 1.18	207,784
较宽 PointNet	87.90 ± 0.27	87.55 ± 0.38	0.35 ± 0.12	442,838
PointProgrammerNet	86.59 ± 0.23	82.47 ± 0.93	4.12 ± 0.71	529,426

纯状态分类器达到 86.59% 干净准确率，比轻量 PointNet++ 低 3.25 个百分点，比较宽 PointNet 低 1.31 个百分点。密度偏移下准确率下降 4.12 个百分点。因此，分类可以仅从可合并状态完成而不保留输入点，其代价是可测量的精度下降。

4.3 可加性与固定状态




图 2: 可加流式处理与固定保留内存。有序和乱序分块写入都能在浮点累加误差范围内复现单批次 FWP 状态。无论点流多长，三个 128×170 的 float32 状态始终占用 255 KiB；保存 XYZ 坐标所需的内存则随观测数量线性增长。

在 32 个物体上，将点云分成 2 至 32 个有序或乱序分块后构造状态；所得结果与一次性构造的最大相对误差低于 5.3×10^{-7} 。这也模拟了多个设备分别编码互不重叠的点子集，再由服务器相加。三个状态共含 65,280 个 float32 标量，即 255 KiB。固定内存不意味着任何情况下都更省内存：裸 XYZ 要到 21,760 点才达到 255 KiB，而 1,024 点的 XYZ 点云明显更小。优势在于点流持续增长时，保留内存仍有严格上界，而且状态保存的是学习得到的几何统计量，而非仅保存原始坐标。

4.4 状态操作




图 3: 流式状态操作。(a) 追加或合并、帧删除和指数衰减相对于独立重建 FWP 状态的最大相对误差，测试对象为 32 个 ShapeNetPart 物体。(b) 普通加法使状态幅值随帧数增长；指数衰减在不改变状态尺寸的情况下限制旧帧的影响。

追加、合并、删除和指数衰减相对于独立重建的平均相对误差分别为 2.11×10^{-7} 、 2.13×10^{-7} 、 3.03×10^{-7} 和 1.77×10^{-7} ，最大值都低于 9.8×10^{-7} 。经过 16 帧，普通加法状态范数为 14.51；使用 $\rho = .9$ 的衰减后，范数限制在 7.42。此实验验证状态代数，不代表时序任务准确率。

4.5 流式效率

在 RTX 3070 Ti Laptop GPU 上，我们对四条常驻设备内存的点流计时，每帧加入 256 个点；每个设置重复 30 次并进行七轮试验。增量更新延迟稳定在约 1.46–1.53 ms。由于启动固定尺寸更新本身存在开销，在累计点




图 4: 设备内存常驻点流的 FWP 状态构建开销。(a) 增量更新只处理新增的 256 点帧, 而重建会处理所有累计点。数据为四条点流、每次 30 次重复、七轮交错试验的挂钟时间中位数, 误差线表示观测范围。(b) 速度提升随历史长度增加, 同时增量状态与重建状态保持数值等价。

数不超过 1,024 时重建略快; 到 2,048、4,096 和 8,192 点时, 增量更新分别快 $1.52\times$ 、 $3.04\times$ 和 $6.06\times$ 。状态相对误差始终低于 6.1×10^{-7} 。

4.6 受控架构审查

五轮、三种子的快速实验每次只改变一个选择。三个分割分支都采用 $170 \rightarrow 160 \rightarrow 160$ 解码器后, 实例 mIoU 变化为 $+0.30 \pm 0.30$ 个百分点, 类别 mIoU 变化为 $+0.15 \pm 0.29$, 同时减少 24,480 个参数。使用不同的初始半径使实例 mIoU 提高 0.74 ± 0.42 , 类别 mIoU 基本不变 (-0.05 ± 0.33)。三个分支统一使用式 (4) 的归一化空间地址后, 相比混合地址公式, 实例和类别 mIoU 分别提高 0.35 ± 0.16 和 0.85 ± 0.37 。分类中, 以中尺度为参考的残差相比直接拼接, 使干净准确率和密度偏移准确率分别提高 2.67 ± 1.60 和 3.78 ± 1.71 。中尺度半径使用 $25\times$ 学习率后, 干净准确率变化不稳定 (0.13 ± 1.03), 但偏移准确率稳定提高 (0.91 ± 0.33), 因此保留这一设置以改善鲁棒性。

5 讨论与局限

本方法面向持续增长或分布式产生的点流。单个传感器可以编码一帧、合并状态并释放该帧。多个相机、LiDAR、机器人或边缘处理器可以分别编




图 5: 三个随机种子的筛选消融实验。分割部分将最终模型分别与不等分支解码器、相同初始半径和混合空间地址公式进行比较；纯状态分类部分比较中尺度参考残差与直接拼接，并改变中尺度半径学习率。柱高表示配对均值变化，误差线表示总体标准差。每次筛选训练五个 epoch。

码不同空间区域或时间窗，再将固定状态发送给服务器。矩阵加法给出与集中式编码相同的表示，因此允许异步到达和分层聚合，原始点集无需离开感知设备。分割服务只需保留计划查询的坐标，分类器则可在不重放历史点的情况下更新证据。这些操作都不需要把新点与全部历史解码点比较。

固定状态同时也是信息瓶颈。PointNet++ 会围绕真实观测点构造邻域，PointNet 会保留逐通道极值；PointProgrammerNet 只保留有限个学习矩表。这可以解释其离线精度差距，分类任务尤其明显。对小点云而言，固定状态也可能比裸 XYZ 更占内存；每个设备都发送一个状态，只有当系统需要固定通信上界或面对长时间点流时才有明显价值。分布式严格等价还要求公共坐标系和一致预处理。分割仍需对每个查询坐标执行一次状态读取。

法线、颜色或强度可以加入值通道，同时继续用 XYZ 建立空间键；法线也可以参与乘积键，但需要处理方向和带宽。当前实验每个任务只覆盖一个数据集，使用 XYZ 输入，只在一块 GPU 上计时，并采用本地受控基线。本文尚未测量不存在坐标的查询精度、时序校准、逐点类别稳定性或 delta 自适应。连续 logits 不意味着预测一定单调改善，也不保证离散标签连续。

6 结论

PointProgrammerNet 用固定可加矩阵概括点云。连续键和二阶值支持无序写入、精确分布式合并、删除、衰减，以及与历史长度无关的增量更新。坐标条件分割和纯状态分类都不在解码点之间做池化。虽然准确率仍低于分层基线，但该模型为集中式或分布式点云推理提供了一个紧凑、可检验、存储有界的流式设计。

CRediT 作者贡献声明

Dian Yu: 概念提出、方法设计、软件实现、验证、形式分析、实验、数据整理、可视化、初稿撰写及修改。

数据可得性

复现论文所报告模型所需的代码作为补充材料提供。ShapeNetPart 和 ModelNet40 均为公开数据集，可从本文引用的原始来源获得。

参考文献

- [1] Angel X. Chang, Thomas Funkhouser, Leonidas Guibas, Pat Hanrahan, Qixing Huang, Zimo Li, Silvio Savarese, Manolis Savva, Shuran Song, Hao Su, Jianxiong Xiao, Li Yi, and Fisher Yu. Shapenet: An information-rich 3d model repository. *arXiv:1512.03012*, 2015.
- [2] Angelos Katharopoulos, Apoorv Vyas, Nikolaos Pappas, and François Fleuret. Transformers are RNNs: Fast autoregressive transformers with linear attention. In *ICML*, volume 119 of *PMLR*, pages 5156–5165, 2020.
- [3] Juho Lee, Yoonho Lee, Jungtaek Kim, Adam Kosiorek, Seungjin Choi, and Yee Whye Teh. Set transformer: A framework for attention-based permutation-invariant neural networks. In *ICML*, volume 97 of *PMLR*, pages 3744–3753, 2019.

- [4] Charles R. Qi, Hao Su, Kaichun Mo, and Leonidas J. Guibas. Pointnet: Deep learning on point sets for 3d classification and segmentation. In *CVPR*, pages 652–660, 2017.
- [5] Charles Ruizhongtai Qi, Li Yi, Hao Su, and Leonidas J. Guibas. Pointnet++: Deep hierarchical feature learning on point sets in a metric space. In *NeurIPS*, volume 30, pages 5099–5108, 2017.
- [6] Imanol Schlag, Kazuki Irie, and Jürgen Schmidhuber. Linear transformers are secretly fast weight programmers. In *ICML*, volume 139 of *PMLR*, pages 9355–9366, 2021.
- [7] Zhirong Wu, Shuran Song, Aditya Khosla, Fisher Yu, Linguang Zhang, Xiaoou Tang, and Jianxiong Xiao. 3d shapenets: A deep representation for volumetric shapes. In *CVPR*, pages 1912–1920, 2015.
- [8] Li Yi, Vladimir G. Kim, Duygu Ceylan, I-Chao Shen, Mengyan Yan, Hao Su, Cewu Lu, Qixing Huang, Alla Sheffer, and Leonidas Guibas. A scalable active framework for region annotation in 3d shape collections. *ACM Transactions on Graphics*, 35(6):210:1–210:12, 2016.
- [9] Manzil Zaheer, Satwik Kottur, Siamak Ravanbakhsh, Barnabas Poczos, Ruslan Salakhutdinov, and Alexander J. Smola. Deep sets. In *NeurIPS*, volume 30, pages 3391–3401, 2017.