

《面向流式点云识别的固定状态可加 FWP 网络》 补充材料

Dian Yu

University of New South Wales, Sydney, NSW 2052, Australia

中文补充材料校对稿

正文已经说明逐点编码器、空间地址、可加外积状态、两个任务头和主要实验。本补充材料只保留正文没有展开、但精确复现和核查方法性质所必需的细节。

1 精确读出与数值稳定措施

1.1 分割

对分支 s ，查询坐标 $\mathbf{q}$ 从固定状态中读出

$$\mathbf{a}_s(\mathbf{q}) = \mathbf{k}_s(\mathbf{q})^\top \mathbf{S}_s \in \mathbb{R}^{170}.$$

其中第一项是读出质量 $\mu_s(\mathbf{q})$ 。当查询位置几乎没有观测支持时，直接除以很小的质量会造成数值不稳定，因此实现采用

$$\epsilon_s = 10^{-3} \text{mean}_{\mathbf{q}'} \mu_s(\mathbf{q}') + 10^{-20}, \quad \tilde{\mu}_s(\mathbf{q}) = \max(\mu_s(\mathbf{q}), \epsilon_s). \quad (1)$$

均值在同一样本的查询坐标上计算，并在反向传播时停止梯度。式 (1) 中的最大值只是两个标量之间的数值下限，不比较点特征，也不是全局最大池化。

$\mathbf{a}_s(\mathbf{q})$ 的其余列分别保存加权坐标、特征、坐标与特征乘积、坐标平方及特征平方之和。除以 $\tilde{\mu}_s$ 后得到 $\bar{\mathbf{x}}_s, \bar{\mathbf{g}}_s, E_{xg,s}, E_{xx,s}, E_{gg,s}$ 。送入分支解码器的描述向量为

$$\mathbf{d}_s(\mathbf{q}) = [\bar{\mathbf{g}}_s, \bar{\mathbf{x}}_s - \mathbf{q}, \log \tilde{\mu}_s, \text{vec}(E_{xg,s} - \mathbf{q}\bar{\mathbf{g}}_s^\top), \text{vech}(E_{xx,s} - \bar{\mathbf{x}}_s\bar{\mathbf{x}}_s^\top), \sqrt{[E_{gg,s} - \bar{\mathbf{g}}_s \odot \bar{\mathbf{g}}_s]_+ + 10^{-8}}]. \quad (2)$$

六个部分的维度依次为 32, 3, 1, 96, 6, 32, 总计 170。协方差和标准差保留均值无法表达的局部变化; $[\cdot]_+$ 只消除浮点舍入产生的微小负方差。

三个分支各自使用结构相同、参数独立的解码器, 其层宽均为 $170 \rightarrow 160 \rightarrow 160$, 并使用 BatchNorm 和 ReLU。三个输出与 32 维坐标特征和 16 维 ShapeNetPart 类别编码拼接, 再经过 $528 \rightarrow 256 \rightarrow 128 \rightarrow 50$ 分割 MLP; 前两层后使用 BatchNorm、ReLU 和 0.3 dropout。每个查询坐标独立处理, 查询点之间没有池化或交互。

1.2 分类

分类阶段不保留坐标或逐点特征。第 j 个状态行的 170 项写成

$$[\mu_{sj}, \mathbf{p}_{sj}, \mathbf{f}_{sj}, \text{vec}(\mathbf{C}_{sj}), \text{vech}(\mathbf{Q}_{sj}), \mathbf{u}_{sj}],$$

分别表示质量、坐标和、特征和、坐标-特征乘积和、对称坐标二阶矩以及特征平方和。行归一化采用

$$\tilde{\mu}_{sj} = \max\left(\mu_{sj}, 10^{-4} R^{-1} \sum_{u=1}^R |\mu_{su}| + 10^{-20}\right), \quad (3)$$

其中下限在反向传播时停止梯度。令 $\bar{\mu}_s = R^{-1} \sum_u \tilde{\mu}_{su}$, 每行除以 $\tilde{\mu}_{sj}$ 后得到

$$\mathbf{d}_{sj}^{\text{row}} = [\bar{\mathbf{g}}_{sj}, \bar{\mathbf{x}}_{sj}, \log(\tilde{\mu}_{sj}/\bar{\mu}_s), \text{vech}(\text{Cov}_{xx,sj}), \text{Std}_{g,sj}, \text{vec}(\text{Cov}_{xg,sj})] \in \mathbb{R}^{170}. \quad (4)$$

六个部分的维度为 32, 3, 1, 6, 32, 96。

每个分支使用独立的 $170 \rightarrow 128 \rightarrow 128$ LayerNorm-GELU 行编码器。两个可学习评分列分别在固定的 128 行上做 softmax 加权汇总; 两份汇总拼接后经过 affine-LayerNorm-GELU 映射, 得到 $\mathbf{h}_s \in \mathbb{R}^{256}$ 。这里的 softmax 始终只处理 128 个状态行, 其计算量不会随历史点数增长。

中尺度摘要作为参考, 细尺度和粗尺度摘要产生修正量

$$\boldsymbol{\delta} = \sigma(a) \tanh(W[\mathbf{h}_f; \mathbf{h}_b] + \mathbf{b}), \quad \mathbf{z}_{\text{cls}} = h_{\text{cls}}(\text{LN}(\mathbf{h}_m + \boldsymbol{\delta})).$$

残差投影从零初始化, $\sigma(a)$ 从 0.1 初始化。分类器 h_{cls} 为 $256 \rightarrow 256 \rightarrow 40$, 使用 GELU 和 0.3 dropout。三个半径都可学习, 只有中尺度半径采用基础学习率的 25 倍并关闭权重衰减, 其余参数均使用基础优化设置。

2 性质证明的补充细节

令 $F_s(\mathbf{x}) = \mathbf{k}_s(\mathbf{x})\mathbf{v}_s(\mathbf{x})^\top$ 表示一个点对分支 s 的秩一 FWP 写入, 则 $\mathbf{S}_s(X) = \sum_{\mathbf{x} \in X} F_s(\mathbf{x})$ 。

命题 1 (顺序、分块与分布式合并). 对任意点多重集合 A, B ,

$$\mathbf{S}_s(A \uplus B) = \mathbf{S}_s(A) + \mathbf{S}_s(B),$$

而且状态不依赖点的输入顺序。若多个设备使用相同的已训练编码器、坐标归一化和参考坐标系, 则中心设备只需相加各设备独立编码的状态, 即可得到与集中处理相同的状态。

证明. 等式两侧展开后都是同一组逐点矩阵 $F_s(\mathbf{x})$ 的有限和。实数运算中, 改变求和顺序或分组方式不会改变结果; Float32 实现只可能因累加次序产生微小舍入差异。□

若保存了待删除子集的聚合状态, 同一等式也允许做状态减法。指数遗忘可写成

$$\mathbf{S}_{s,t} = \rho \mathbf{S}_{s,t-1} + \mathbf{S}_s(X_t), \quad 0 \leq \rho \leq 1.$$

减法只能移除一个集合的聚合贡献, 不能从状态中恢复集合内的单点。

命题 2 (固定保留内存与增量代价). 若分支 s 的状态有 R_s 行和 D_s 列, 保留内存为 $O(\sum_s R_s D_s)$, 与历史长度无关。编码 M 个新点的代价为 $O(M \sum_s R_s D_s)$, 且无需重访旧点。

证明. 系统只永久保留固定尺寸矩阵。无论先前处理过多少批数据, 新批次都只产生尺寸不变的新外积并将其加入现有状态。□

用 $t \in [0, 1]$ 表示一个新证据点的强度, 则

$$\mathbf{S}_s(t) = \mathbf{S}_s^{\text{old}} + t F_s(\mathbf{x})$$

关于 t 是仿射函数。高斯地址、softmax、带正下限的归一化、仿射层、ReLU 或 GELU 以及稳定化平方根都是连续函数, 因此分类 logits 和固定查询坐标的分割 logits 随 t 连续且分段光滑。状态固定时, 分割 logits 对查询坐标也具有相同性质。最终 $\arg\max$ 标签仍可能在决策边界处跳变。

3 受控筛选与复现信息

每组受控筛选内部使用相同的数据划分和优化流程，训练 5 轮并采用随机种子 0、1、2。表 1 只列出决定最终结构的配对比较；正文表格报告最终 20 轮结果。

表 1: 五轮受控筛选；正值表示最终保留的设计更好。

保留设计	对照设计	配对变化
分割：相同解码器	中尺度使用不同解码器	+0.30±0.30 实例；+0.15±0.29 类别
分割：不同半径初值	相同半径初值	+0.74±0.42 实例；-0.05±0.33 类别
分割：统一归一化键	混合键定义	+0.35±0.16 实例；+0.85±0.37 类别
分类：中尺度残差	直接拼接	+2.67±1.60 干净；+3.78±1.71 扰动
分类：中尺度半径 25 倍学习率	基础半径学习率	+0.13±1.03 干净；+0.91±0.33 扰动

分割变化对应实例 mIoU 和类别 mIoU。相同解码器还减少 24,480 个参数。分类的学习率设置主要依据其稳定的分布变化准确率收益，而不是波动较大的干净准确率变化。

随论文发布的最小代码包含 341,909 参数的分割模型、529,426 参数的分类模型、数据加载、训练循环、状态操作检查和三随机种子参考值。CODE_REPRODUCTION.md 说明环境、数据目录、运行命令和流式接口。验证可加性时应使用评估模式，因为此时 BatchNorm 使用证明所假定的固定运行统计量。